


# 第二章：线性模型



- 2.1 线性回归
- 2.2 梯度更新方式
- 2.3 线性回归矩阵形式
- 2.4 最大似然估计
- 2.5 分类指标
- 2.6 逻辑斯蒂回归



西安交通大学  
XI'AN JIAOTONG UNIVERSITY

## 2.1 线性回归

## 2.1 线性回归

### 线性判别模型

#### 判别模型

##### □ 性质

- 建模预测变量和观测变量之间的关系
- 也称作条件模型 (Conditional Models)

##### □ 分类

- 确定性判别模型:  $y = f_\theta(x)$
- 概率判别模型:  $p_\theta(y|x)$

本节集中介绍线性判别模型 (linear regression)

## 2.1 线性回归

### 线性判别模型

#### 判别模型

##### □ 性质

- 建模预测变量和观测变量之间的关系
- 也称作条件模型 (Conditional Models)

##### □ 分类

- 确定性判别模型:  $y = f_{\theta}(x)$
- 概率判别模型:  $p_{\theta}(y|x)$

#### 线性判别模型 (linear regression)

$$y = f_{\theta}(x) = \theta_0 + \sum_{j=1}^d \theta_j x_j = \theta^\top x$$
$$x = (1, x_1, x_2, \dots, x_d)$$

## 2.1 线性回归

### 学习目标

- 使预测值和真实值的距离越近越好

$$\min_{\theta} \frac{1}{N} \sum_{i=1}^N \mathcal{L}(y_i, f_{\theta}(x_i))$$


- 损失函数 $\mathcal{L}(y_i, f_{\theta}(x_i))$  测量预测值和真实值之间的误差，越小越好
- 具体损失函数的定义依赖于具体的数据和任务
- 最广泛使用的损失回归函数：平方误差(squared loss)

$$\mathcal{L}(y_i, f_{\theta}(x_i)) = \frac{1}{2} (y_i - f_{\theta}(x_i))^2$$

## 2.1 线性回归

### 平方误差

$$\mathcal{L}(y_i, f_\theta(x_i)) = \frac{1}{2} (y_i - f_\theta(x_i))^2$$





- 对预测误差大的有更大的惩罚
- 容忍很小的预测误差
  - 观测误差等
  - 提升模型的泛化能力

## 2.1 线性回归

### 最小均方误差回归

- 优化目标是最小化训练数据上的均方误差

$$J_{\theta} = \frac{1}{2N} \sum_{i=1}^N (y_i - f_{\theta}(x_i))^2$$
$$\min_{\theta} J_{\theta}$$



## 2.2 梯度更新方式

### 批量梯度下降

- 优化目标

$$J(\theta) = \frac{1}{2N} \sum_{i=1}^N (y_i - f_\theta(x_i))^2 \quad \min_{\theta} J(\theta)$$

- 根据整个批量数据的梯度更新参数  $\theta_{\text{new}} \leftarrow \theta_{\text{old}} - \eta \frac{\partial J(\theta)}{\partial \theta}$

$$\begin{aligned}\frac{\partial J(\theta)}{\partial \theta} &= -\frac{1}{N} \sum_{i=1}^N \left( (y_i - f_\theta(x_i)) \frac{\partial f_\theta(x_i)}{\partial \theta} \right) \\ &= -\frac{1}{N} \sum_{i=1}^N (y_i - f_\theta(x_i)) x_i \\ \theta_{\text{new}} &= \theta_{\text{old}} + \eta \frac{1}{N} \sum_{i=1}^N (y_i - f_\theta(x_i)) x_i\end{aligned}$$

## 2.2 梯度更新方式

### 随机梯度下降

#### □ 优化目标

$$J^{(i)}(\theta) = \frac{1}{2} (y_i - f_{\theta}(x_i))^2 \quad \min_{\theta} \frac{1}{N} \sum_i J^{(i)}(\theta)$$

$$\square \text{ 根据整个批量数据的梯度更新参数 } \theta_{\text{new}} = \theta_{\text{old}} - \eta \frac{\partial J^{(i)}(\theta)}{\partial \theta}$$

$$\begin{aligned} \frac{\partial J^{(i)}(\theta)}{\partial \theta} &= -(y_i - f_{\theta}(x_i)) \frac{\partial f_{\theta}(x_i)}{\partial \theta} \\ &= -(y_i - f_{\theta}(x_i)) x_i \end{aligned}$$

$$\theta_{\text{new}} = \theta_{\text{old}} + \eta (y_i - f_{\theta}(x_i)) x_i$$

#### □ 对比批量梯度下降

- 更快地更新参数(**优点**)
- 学习中不确定性或震荡(**缺点**)

## 2.2 梯度更新方式

### 小批量梯度下降

#### 算法思想

批量梯度下降和随机梯度下降的结合

#### 训练步骤

- 将整个训练集分成  $K$  个小批量 (mini-batches)

$$\{1, 2, 3, \dots, K\}$$


- 对于每一个小批量  $k$ , 做一步批量下降来降低

$$J^{(k)}(\theta) = \frac{1}{2N_k} \sum_{i=1}^{N_k} (y_i - f_\theta(x_i))^2$$

- 对于每一个小批量, 更新参数  $\theta_{\text{new}} = \theta_{\text{old}} - \eta \frac{\partial J^{(k)}(\theta)}{\partial \theta}$

## 2.2 梯度更新方式


- 结合了批量梯度下降和随机梯度下降的优点
  - 批量梯度下降的优秀的稳定性
  - 随机梯度下降的快速更新
- 小批量梯度下降很适合使用在并行化计算中
  - 将每个小批量数据进一步切分，每个线程分别计算梯度，最后再加和这些梯度



## 2.2 梯度更新方式


### 基本搜索步骤

- 随机选择一个参数初始化  $\theta$
- 根据数据和梯度算法来更新  $\theta$
- 直到走到局部一个最小区域(**local minimum**)



## 2.2 梯度更新方式

凸优化目标函数具有唯一最小点



- 不同的初始化参数最终也会学习到相同的最优值


## 2.2 梯度更新方式

### 凸集 (Convex Set)


一个点集 $S$ 被称为凸集，当且仅当该 $S$ 里的任意两点A和B的连线上任意一点同样属于 $S$

$$tx_1 + (1 - t)x_2 \in S$$

$$\text{for all } x_1, x_2 \in S, 0 \leq t \leq 1$$




凸集



非凸集

## 2.2 梯度更新方式

### 凸函数 (Convex Function)



#### 凸函数的定义

$f: \mathbb{R}^n \rightarrow \mathbb{R}$  是凸函数:  $\text{dom } f$  是一个凸集, 并且满足



$$f(tx_1 + (1 - t)x_2) \leq tf(x_1) + (1 - t)f(x_2)$$

$$\forall x_1, x_2 \in \text{dom } f, 0 \leq t \leq 1$$

## 2.2 梯度更新方式

### 学习率的选择

$$\theta_{\text{new}} = \theta_{\text{old}} - \eta \frac{\partial J(\theta)}{\partial \theta}$$



- 初始点可能距离最优点太远，从而导致收敛速度慢
  - 可能越过最优点
  - 可能无法收敛
  - 甚至可能发散
- 要检查梯度下降是否有效工作，可以打印出每几个迭代得到的损失  $J(\theta)$ ，如果发现  $J(\theta)$  并没有正常地下降，调整学习率  $\eta$

## 2.3 线性回归矩阵形式

从代数视角来看线性回归

训练数据矩阵

$$X = \begin{pmatrix} \mathbf{x}^{(1)} \\ \mathbf{x}^{(2)} \\ \vdots \\ \mathbf{x}^{(n)} \end{pmatrix} = \begin{pmatrix} x_1^{(1)} & x_2^{(1)} & \dots & x_d^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \ddots & x_d^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(n)} & x_2^{(n)} & \dots & x_d^{(n)} \end{pmatrix}$$

参数  $\theta = \begin{pmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_d \end{pmatrix}$  标签  $y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$

预测

$$\hat{\mathbf{y}} = X\theta = \begin{pmatrix} \mathbf{x}^{(1)}\theta \\ \mathbf{x}^{(2)}\theta \\ \vdots \\ \mathbf{x}^{(n)}\theta \end{pmatrix}$$

目标函数

$$J(\theta) = \frac{1}{2} (\mathbf{y} - \hat{\mathbf{y}})^T (\mathbf{y} - \hat{\mathbf{y}}) = \frac{1}{2} (\mathbf{y} - X\theta)^T (\mathbf{y} - X\theta)$$

## 2.3 线性回归矩阵形式

目标函数

$$J(\boldsymbol{\theta}) = \frac{1}{2} (\mathbf{y} - \mathbf{X}\boldsymbol{\theta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\theta}) \quad \min_{\boldsymbol{\theta}} J(\boldsymbol{\theta})$$

对参数向量的梯度

$$\frac{\partial J(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = -\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\theta})$$

最优参数求解

$$\frac{\partial J(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = 0 \rightarrow \mathbf{X}^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\theta}) = 0$$

$$\rightarrow \mathbf{X}^\top \mathbf{y} = \mathbf{X}^\top \mathbf{X}\boldsymbol{\theta}$$

$$\rightarrow \hat{\boldsymbol{\theta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$


## 2.3 线性回归矩阵形式

预测值

$$\hat{y} = X(X^\top X)^{-1}X^\top y = Hy$$

$H$ :帽子矩阵

几何解释



- 数据矩阵的列向量 $[x_1, x_2, \dots, x_d]$ 张成一个 $\mathbb{R}^n$ 上的子空间
- $H$ 就是将标签向量 $y$ 投影到该子空间的映射

$$X = \begin{pmatrix} x_1^{(1)} & x_2^{(1)} & \dots & x_d^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \ddots & x_d^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(n)} & x_2^{(n)} & \dots & x_d^{(n)} \end{pmatrix} = [x_1, x_2, \dots, x_d] \quad y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

## 2.3 线性回归矩阵形式

$X^T X$ 为奇异矩阵的情况

- 当数据矩阵的一些列向量线性相关时
  - 例如  $x_2 = 3x_1$
- $X^T X$ 为奇异矩阵，所以  $\hat{\theta} = (X^T X)^{-1} X^T y$  无法被直接计算。

### 解决方案

- 正则化 (Regularization)
- $J(\mu) = \frac{1}{2} (y - X\theta)^T (y - X\theta) + \frac{\lambda}{2} \|\theta\|_2^2$

## 2.3 线性回归矩阵形式

带正则项的线性回归矩阵形式

优化目标

$$J(\boldsymbol{\theta}) = \frac{1}{2} (\mathbf{y} - \mathbf{X}\boldsymbol{\theta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\theta}) + \frac{\lambda}{2} \|\boldsymbol{\theta}\|_2^2 \quad \min_{\boldsymbol{\theta}} J(\boldsymbol{\theta})$$

对参数向量的梯度

$$\frac{\partial J(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = -\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\theta}) + \lambda \boldsymbol{\theta}$$

最优参数求解

$$\frac{\partial J(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = 0 \rightarrow -\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\theta}) + \lambda \boldsymbol{\theta} = 0$$

$$\rightarrow \mathbf{X}^\top \mathbf{y} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}) \boldsymbol{\theta}$$

$$\rightarrow \hat{\boldsymbol{\theta}} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}$$

## 2.4 最大似然估计

### 判别模型

- 建模预测变量和观测变量之间的关系
- 又名条件模型 (Conditional Models)
- 确定性判别模型:  $y = f_{\theta}(x)$
- 概率判别模型:  $p_{\theta}(y|x)$

### 带高斯白噪声的线性拟合

$$y = f_{\theta}(x) + \epsilon = \theta_0 + \sum_{j=1}^d \theta_j x_j + \epsilon = \theta^T x + \epsilon$$


$$\epsilon \sim \mathcal{N}(0, \sigma^2)$$

$$x = (1, x_1, x_2, \dots, x_d)$$

## 2.4 最大似然估计

### 优化目标

最大似然 (likelihood)



### 一个数据点的标签预测似然

$$p(y|x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y-\theta^T x)^2}{2\sigma^2}}$$

## 2.4 最大似然估计

概率判别模型的学习

最大化训练数据的似然

$$\max_{\theta} \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y_i - \theta^\top x_i)^2}{2\sigma^2}}$$

最大化训练数据的对数似然

$$\log \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y_i - \theta^\top x_i)^2}{2\sigma^2}} = \sum_{i=1}^N \log \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y_i - \theta^\top x_i)^2}{2\sigma^2}} = -\sum_{i=1}^N \frac{(y_i - \theta^\top x_i)^2}{2\sigma^2} + \text{const}$$

$$\min_{\theta} \sum_{i=1}^N (y_i - \theta^\top x_i)^2 \quad \text{等价于最小均方误差学习}$$

## 2.5 分类指标

### 评估指标


		预测	
		1	0
标签	1	True Positive	False Negative
	0	False Positive	True Negative

#### □ True / False

- True: 预测 = 标签
- False: 预测  $\neq$  标签

#### □ Positive / Negative

- Positive: 预测  $y = 1$
- Negative: 预测  $y = 0$



## 2.5 分类指标

### 评估指标

		预测	
		1	0
标签	1	True Positive	False Negative
	0	False Positive	True Negative

### 精度(Accuracy)

- 分类正确的样本占样本总数的比例

$$\text{Acc} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

## 2.5 分类指标

### 评估指标

		预测	
		1	0
标签	1	True Positive	False Negative
	0	False Positive	True Negative

### 精确率(Precision)

- 预测为1的样本中标签为1的比例

$$\text{Prec} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

		预测	
		1	0
标签	1	True Positive	False Negative
	0	False Positive	True Negative

### 召回率(Recall)

- 标签为1的样本中预测为1的比例

$$\text{Rec} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$


## 2.5 分类指标

### 评估指标

#### □ 精确率和召回率的权衡

$$\hat{y} = \begin{cases} 1, & p_{\theta}(y = 1|x) > h \\ 0, & \text{otherwise} \end{cases}$$

- 阈值越高，精确率越高，召回率越低
  - 极端情况：阈值=0.99
- 阈值越低，精确率越低，召回率越高
  - 极端情况：阈值=0



#### □ F1分数

$$F1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

## 2.5 分类指标

### 评估指标


- 基于排序的度量：ROC曲线下面积 (AUC)

- True Positive Rate

$$TPR = \frac{TP}{TP + FN}$$

- False Positive Rate


$$FPR = \frac{FP}{FP + TN}$$



## 2.5 分类指标

### 评估指标


- 基于排序的度量：ROC曲线下面积 (AUC)



## 2.5 分类指标

### 评估指标

#### □ AUC计算例子



$$AUC = 0.75$$

Prediction	Label
0.91	1
0.85	0
0.77	1
0.72	1
0.61	0
0.48	1
0.42	0
0.33	0

## 2.6 逻辑斯谛回归

### 分类问题

#### 给定

- 样本空间 $\mathbb{X}$ 中一个样本 $x$  ( $x \in \mathbb{X}$ )的描述
- 一个固定的类别集:  $C = \{c_1, c_2, \dots, c_m\}$

#### 求解


- $x$ 的类别: $f(x) \in C$ , 其中 $f(x)$ 是一个定义域为 $\mathbb{X}$ , 值域为 $C$ 的类别函数

#### 二分类


- 假如类别集是二元的, 即 $C = \{0,1\}$ ({错误, 正确}, {负, 正}), 那么这就是二分类问题

## 2.6 逻辑斯谛回归

### 二分类



线性可分



线性不可分

线性可分性：是否存在  $ax_1 + bx_2 + c = 0$

使得对于所有的正例：  $ax_1 + bx_2 + c > 0$

对于所有的负例：  $ax_1 + bx_2 + c < 0$

## 2.6 逻辑斯谛回归

### 线性判别模型

#### 判别模型

##### □ 性质

- 建模预测变量和观测变量之间的关系
- 也称作条件模型(**Conditional Models**)

##### □ 分类

- 确定性判别模型:  $y = f_\theta(x)$ 
  - 对于分类任务不可微分
- 概率判别模型:  $p_\theta(y|x)$ 
  - 对于分类任务可微分

#### 二分类

$$p_\theta(y = 1|x)$$

$$p_\theta(y = 0|x) = 1 - p_\theta(y = 1|x)$$

## 2.6 逻辑斯谛回归

### 熵 (Entropy)

- 在信息论中，熵用来衡量一个随机事件的不确定性
- 自信息 (Self Information)

$$I(x) = -\log(p(x))$$

- $x$ 表示一个事件
- $p(x)$ 表示 $x$ 发生的概率
- 信息量， $x$ 越不可能发生时，它一旦发生后的信息量就越大

## 2.6 逻辑斯谛回归

### 熵 (Entropy)

- 在信息论中，熵用来衡量一个随机事件的不确定性
- 自信息 (Self Information)

$$I(x) = -\log(p(x))$$

- 熵的计算

$$\begin{aligned} H(X) &= \mathbb{E}_X[I(x)] \\ &= \mathbb{E}_X[-\log(p(x))] \\ &= -\sum_{x \in \mathcal{X}} p(x) \log p(x) \end{aligned}$$

## 2.6 逻辑斯谛回归

### 熵 (Entropy)

- 假设对于这门课程，我们有三种可能的情况发生

事件编号	事件	概率 $p$	信息量 $I$
$x_1$	优秀	$p = 0.7$	$I = -\ln(0.7) = 0.36$
$x_2$	及格	$p = 0.2$	$I = -\ln(0.2) = 1.61$
$x_3$	不及格	$p = 0.1$	$I = -\ln(0.1) = 2.30$

- 某某同学不及格！好大的信息量！相比较来说，“优秀”事件的信息量反而小了很多。上面的问题的熵是：

$$\begin{aligned}H(p) &= -[p(x_1) \ln p(x_1) + p(x_2) \ln p(x_2) + p(x_3) \ln p(x_3)] \\&= 0.7 \times 0.36 + 0.2 \times 1.61 + 0.1 \times 2.30 \\&= 0.804\end{aligned}$$

## 2.6 逻辑斯谛回归

### 损失函数

#### 交叉熵损失

- 离散的情况  $H(p, q) = - \sum_x p(x) \log q(x)$
- 连续的情况  $H(p, q) = - \int_x p(x) \log q(x) dx$

#### 分类问题计算交叉熵损失

Ground Truth	0	1	0	0	0
Prediction	0.1	0.6	0.05	0.05	0.2

$$\mathcal{L}(y, x, p_\theta) = - \sum_k \delta(y = c_k) \log p_\theta(y = c_k | x)$$

$$\delta(z) = \begin{cases} 1, & z \text{ is true} \\ 0, & \text{otherwise} \end{cases}$$

## 2.6 逻辑斯谛回归

### 二分类的交叉熵

	Class 1	Class 2
真实值	0	1
预测值	0.3	0.7

### □ 损失函数

$$\begin{aligned}\mathcal{L}(y, x, p_\theta) &= -\delta(y = 1) \log p_\theta(y = 1|x) - \delta(y = 0) \log p_\theta(y = 0|x) \\ &= -y \log p_\theta(y = 1|x) - (1 - y) \log(1 - p_\theta(y = 1|x))\end{aligned}$$

## 2.6 逻辑斯谛回归


### 逻辑斯谛(Logistic)回归

- 逻辑斯谛回归是一个二分类模型

$$p_{\theta}(y=1|x) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

$$p_{\theta}(y=0|x) = \frac{e^{-\theta^T x}}{1 + e^{-\theta^T x}}$$

### Sigmoid函数



- 交叉熵损失函数

$$\mathcal{L}(y, x, p_{\theta}) = -y \log \sigma(\theta^T x) - (1 - y) \log(1 - \sigma(\theta^T x))$$

- 梯度

$$\begin{aligned}\frac{\partial \mathcal{L}(y, x, p_{\theta})}{\partial \theta} &= -y \frac{1}{\sigma(\theta^T x)} \sigma(z)(1 - \sigma(z))x - (1 - y) \frac{-1}{1 - \sigma(\theta^T x)} \sigma(z)(1 - \sigma(z))x \\ &= (\sigma(\theta^T x) - y)x\end{aligned}$$

$$\theta \leftarrow \theta + \eta (\sigma(\theta^T x) - y)x$$

线性回归:  $\theta_{\text{new}} = \theta_{\text{old}} + \eta(y_i - f_{\theta}(x_i))x_i$

$$\frac{\partial \sigma(z)}{\partial z} = \sigma(z)(1 - \sigma(z))$$

## 2.6 逻辑斯谛回归

### 标签的决定

- 逻辑斯谛回归求出的概率

$$p_{\theta}(y = 1|x) = \delta(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$


$$p_{\theta}(y = 0|x) = \frac{e^{-\theta^T x}}{1 + e^{-\theta^T x}}$$

- 设置阈值(threshold) $h$ 决定示例最终标签

$$\hat{y} = \begin{cases} 1, & p_{\theta}(y = 1|x) > h \\ 0, & \text{otherwise} \end{cases}$$

## 2.6 逻辑斯谛回归

### 多分类



### 多分类交叉熵

$$\mathcal{L}(y, x, p_\theta) = - \sum_k \delta(y = c_k) \log p_\theta(y = c_k | x)$$

$$\delta(z) = \begin{cases} 1, & z \text{ is true} \\ 0, & \text{otherwise} \end{cases}$$

真实值	0	1	0
预测值	0.1	0.7	0.2

## 2.6 逻辑斯谛回归

### 多类别逻辑斯谛回归

#### □ 类别集

$$C = \{c_1, c_2, \dots, c_m\}$$

#### □ 预测 $p_\theta(y = c_j | x)$ 的概率

$$p_\theta(y = c_j | x) = \frac{e^{\theta_j^\top x}}{\sum_{k=1}^m e^{\theta_k^\top x}} \quad \text{for } j = 1, \dots, m$$

#### □ Softmax

- 参数  $\theta = \{\theta_1, \theta_2, \dots, \theta_m\}$
- 可以标准化成  $m - 1$  组参数

## 2.6 逻辑斯谛回归

### 多类别逻辑斯谛回归

- 对一个示例的学习 ( $x, y = c_j$ )

- 最大对数化似然(log-likelihood)

$$\max_{\theta} \log p_{\theta}(y = c_j | x)$$


- 梯度

$$\begin{aligned}\frac{\partial \log p_{\theta}(y = c_j | x)}{\partial \theta_j} &= \frac{\partial}{\partial \theta_j} \log \frac{e^{\theta_j^\top x}}{\sum_{k=1}^m e^{\theta_k^\top x}} \\ &= x - \frac{\partial}{\partial \theta_j} \log \sum_{k=1}^m e^{\theta_k^\top x} \\ &= x - \frac{e^{\theta_j^\top x}}{\sum_{k=1}^m e^{\theta_k^\top x}} x = (1 - p_{\theta}(y = c_j | x)) x\end{aligned}$$

## 垃圾邮件分类

### 二分类任务：

- 只用绝对值排名靠前的k个特征，重新训练和评估模型性能



- 是否可以显式地训练参数，以优先构建一个“稀疏”的模型？为什么？
  - 低复杂度的模型不容易过拟合
- 模型训练的目的是为了最小化损失函数：


$$\hat{\theta} = \min_{\theta} Loss(\theta)$$

如何改变这个损失函数以降低训练出来的模型的复杂度？

## 垃圾邮件分类

### 二分类任务：

- 在损失函数中引入正则化项
- 经典正则化方法 $\|\theta\|_q$ 的数值分布图



“正则化”后的损失函数

$$\hat{\theta} = \min_{\theta} \{ Loss(\theta) + c \|\theta\|_0 \}$$

$c$  控制正则化项的相对重要性

# 线性模型总结

- 线性回归是机器学习中最基础的参数化学习模型，线性回归任务是机器学习中最基础的有监督学习任务。
- 逻辑斯谛回归，虽然其名字包含“回归”二字，但它是最具有代表性的机器学习分类模型，至今还在学术研究和工业落地场景中被广泛使用。

	激活函数	损失函数	优化方法
线性回归	-	$(y - \mathbf{w}^T \mathbf{x})^2$	最小二乘、梯度下降
Logistic 回归	$\sigma(\mathbf{w}^T \mathbf{x})$	$y \log \sigma(\mathbf{w}^T \mathbf{x})$	梯度下降
Softmax 回归	$\text{softmax}(W^T \mathbf{x})$	$y \log \text{softmax}(W^T \mathbf{x})$	梯度下降